

Personagens de jogos mais dinâmicos, uma mini *survey* da literatura

Douglas C. Carvalho¹, Gabriel C. Carvalho¹

¹ Faculdade de Engenharia – Departamento de Engenharia de Sistemas e Computação
Universidade do Estado do Rio de Janeiro (UERJ) – Rio de Janeiro – RJ – Brazil

carvalho.douglas@graduacao.uerj.br, gabrielc@eng.uerj.br

Resumo.

1. Introdução

Durante o processo de desenvolvimento de jogos, os desenvolvedores geralmente se esforçam para manter o engajamento dos jogadores por um longo período [Przybylski et al. 2010]. Isso podendo ganhar destaque em jogos possuem algum tipo de combate com *Non-Playable Characters* (NPC), no qual os desenvolvedores buscam criar videogames com recursos personalizados aumentam a imersão, o engajamento, a empolgação e o desafio dos jogadores [Bontchev 2016], sem tornar os combates repetitivos, criando uma experiência do jogador agradável. Dessa forma, a experiência do jogador refere-se ao efeito global de sentimentos, pensamentos, emoções e comportamentos vivenciados pelo jogador durante a partida, incluindo a experiência de imersão, a experiência de participação no jogoe e a experiência de satisfação de demandas [Mi and Gao 2022].

Como alternativa, as medidas heurísticas tradicionais usadas em mecânicas de combate, muitas vezes, limitadas demais para atender à ampla gama de expectativas dos jogadores [Moon et al. 2022], a utilização de machine-learning se mostra uma alternativa promissora para *Dynamic Difficulty Adjustment* (DDA) em jogos. Portanto, DDA é uma tecnologia muito usada que pode manter o interesse do jogador e assegurar uma boa experiência de jogo, modificando automaticamente parâmetros, comportamentos e cenas em tempo real, de acordo com o nível de habilidade do jogador [Mi and Gao 2022].

Por isso, foram analisados diversos artigos que abordam diferentes formas de implementação de *machine-learning* em mecânicas de combate, em diversos gêneros de jogos. Tendo sido usado como referência neste artigo o *survey* [Mortazavi et al. 2024].

2. Método

O método usado para analisar os artigos consiste na análise do *abstract* e conclusão de cada artigo de interesse. Identificação de pontos de relevantes como, tecnologia proposta no artigo, tipo de jogo testado, aspecto o qual se buscou aprimorar no jogo e o objetivo proposto no artigo.

2.1. Banco de dados usado na busca

Considerando que os jogos constituem uma área multidisciplinar [Mortazavi et al. 2024], foi usado a search engine Google Scholar. Um mecanismo de busca online gratuito que permite pesquisar literatura acadêmica e científica, incluindo artigos revisados por pares, teses, livros e decisões judiciais.

2.2. Termos de busca

Os termos de busca usados foram escolhidos com base na proposta inicial de explorar DDA em jogos, sendo esses:

1. *Intelligent Adaptive Games*
2. *Fighting Games DDA*

A busca na literatura incluiu artigos completos de periódicos e conferências publicados em inglês entre o período de 2020 e 2026.

2.3. Critérios de inclusão e exclusão

Os artigos selecionados tiveram que satisfazer os seguintes critérios para ser incluídos na análise:

- Data de publicação entre 2020 e 2026
- Mais de 5 citações

Além dos artigos que satisfizeram as condições acima, também foram incluídos publicações em periódicos e conferências que desenvolveram e avaliaram empiricamente técnicas para o ajuste dinâmico de dificuldade ou o ajuste adaptativo de níveis de jogo em entretenimento digital.

2.4. Processo de triagem

Depois da aplicação dos termos de busca estabelecidos, a seleção foi feita através da análise do abstract do artigo e da sua conclusão para determinar sua relevância a proposta.

Após essa avaliação inicial, restaram 6 publicações que satisfizeram as condições de inclusão para análise mais detalhada e coleta de dados.

3. Resultados

Nesta seção, os métodos utilizados nos artigos selecionados são analisados com base nos dados que foram apresentados na tabela 1. Esses dados oferecem uma visão geral dos tipos de artigos publicados na área e os avanços no ajuste de dificuldade em jogos.

Segundo a literatura, os métodos utilizados podem ser abordados de duas maneiras [Lopes and Bidarra 2011]. A primeira abordagem envolve a manipulação de parâmetros do jogo, como o número de inimigos ou o poder dos oponentes, durante a partida. Os desenvolvedores projetam um sistema de ajuste de nível ou de dificuldade que modifica a dificuldade do jogo com base no desempenho, na personalidade ou nas características dos jogadores [Lara-Alvarez et al. 2018]. A segunda abordagem personaliza o ambiente ou os elementos do jogo com base nas expectativas e características dos jogadores, sendo que os elementos selecionados não determinam necessariamente a dificuldade do jogo [Lavoué et al. 2018].

Nesta *survey*, focamos na análise de artigos que utilizaram a primeira abordagem para a adaptação, em tempo real, dos desafios dos jogos, buscando garantir uma experiência satisfatória e envolvente para os jogadores.

Tabela 1. Lista de artigos incluídos

Referência	Método usado	Gênero do jogo	Modificação feita	Objetivo
[Fuchs et al. 2024]	DDA <i>framework</i> personalizado que combina <i>imitation learning</i> e <i>reinforcement learning</i>	<i>Fighting</i>	Criação de oponentes que usam AI para se adaptar ao comportamento individual do jogador em tempo real	Explorar o balanceamento da dificuldade do jogo utilizando agentes baseados em <i>machine learning</i> para desafiar os jogadores de acordo com seu comportamento atual
[Zeng and Sweetser 2022]	DDA	<i>Sandbox</i> e <i>survival</i>	Sistema de DDA focado no ajuste dos <i>mobs</i> ao redor dos jogadores	Buscar melhorar a experiência de todos os jogadores, adequando melhor os níveis dos <i>mobs</i> aos níveis de habilidade coletivos dos jogadores dentro de uma área local
[Moon et al. 2022]	DDA com <i>Monte Carlo tree search</i> e estado do jogador	<i>Fighting</i>	Estados dos jogadores como uma função de pontuação para determinar a ação dos agentes do jogo e ajustar automaticamente a dificuldade do jogo	Melhorar a experiência dos jogadores ajustando a habilidade dos agentes do jogo
[Mi and Gao 2022]	<i>Belgian artificial intelligence</i>	<i>Action role-playing</i>	Sistema de gerenciamento de combate	Propor um algoritmo de <i>Belgian artificial intelligence</i> melhorado com DDA
[Kim et al. 2020]	Agente de AI usando <i>deep reinforcement learning</i> com <i>self-play</i> e <i>Monte Carlo Tree Search</i>	<i>Fighting</i>	Sistema de gerenciamento de combate	Gerar uma AI para jogos de luta capaz de competir contra outras AIs que participaram de competições anteriores no ambiente de jogos <i>FightingICE</i>
[Pagalyte et al. 2020]	<i>Reinforcement learning-based DDA</i>	<i>Turn-based battle</i>	Nas escolhas de ações do agente, em vez do ambiente ou das estatísticas do agente	Alcançar um <i>game flow</i> envolvente por meio da introdução de DDA e RL em jogos de batalha baseados em turnos

3.1. *Dynamic Difficulty Adjustment*

O *Dynamic difficulty adjustment* (DDA) consiste em duas etapas [Zohaib 2018]. Primeiramente, mede-se o nível de habilidade dos jogadores por meio de uma função de pontuação. Em seguida, ajusta-se a dificuldade do jogo, de acordo com os níveis de habilidade estimados, de diversas formas, como: [Moon et al. 2022] como, o ajuste de parâmetros no jogo [Denisova and Cairns 2015], a manipulação do ambiente de jogo [Duque et al. 2020, Lora et al. 2016] e a utilização agentes de jogo [Demediuk et al. 2017, Ishihara et al. 2018], sendo essas abordagens utilizadas para controlar o nível de dificuldade.

3.2. DDA com *Monte Carlo tree search* e o estado do jogador

Por meio da utilização de agentes de IA como apresentado em [Demediuk et al. 2017, Ishihara et al. 2018], nos quais é relatado um método de utiliza um agente de DDA baseado em *Monte Carlo tree search* (MCTS) em um jogo de luta. Onde a dificuldade do jogo é manipulada, por meio da implementação de um agente de DDA que utiliza a diferença de *health points* (HP) entre o jogador e o agente como função de pontuação, empregando um algoritmo MCTS de maneira semelhante à abordagem apresentada em [Moon et al. 2022].

Contudo, essas técnicas de medição das habilidades dos jogadores que utilizam funções de pontuação heurísticas especificadas pelos desenvolvedores pressupõem que ajustar a dificuldade do jogo por meio dessas métricas (com base em HP, pontuação no jogo, dano, etc.) pode aumentar o *player experience* (PX). No entanto, a PX e a dificuldade do jogo ajustada por essas medidas frequentemente apresentam inconsistências [Ang and Mitchell 2017, Constant and Levieux 2019].

Por isso, em [Moon et al. 2022], os estados do jogador são utilizados no treinamento da IA do jogo juntamente com o MCTS, permitindo que o DDA se ajuste automaticamente e progressivamente às ações dos oponentes. Essa abordagem considera que a dificuldade do jogo pode evocar diversos estados cognitivos e emocionais que podem impactar a PX [Kivikangas et al. 2011]. Nesse contexto, o MCTS buscando a próxima ação, considerada quase ótima para a IA do jogo, simulando uma grande quantidade de situações possíveis a partir do estado atual do jogo.

Para tanto, as simulações do MCTS consistem em quatro etapas: *selection*, *expansion*, *simulation* e *backpropagation*. Em cada iteração, o estado atual é definido como o nó raiz. Em seguida, as quatro etapas da busca em árvore são executadas dentro de um limite de tempo predeterminado. Após a conclusão da busca, o agente escolhe o nó filho mais visitado ou aquele de maior valor para realizar a próxima ação [Moon et al. 2022].

Sendo assim, a principal diferença entre o modelo atual e o método de DDA heurístico é a utilização direta do estado do jogador como função de pontuação para o MCTS, em vez de funções heurísticas, como pontuação do jogo, taxa de vitória e diferenças de HP. Onde o modelo do estado do jogador combina dos registros de partidas reais e das partidas simuladas pelo MCTS para prever como o estado do jogador se modificará no futuro usando *machine learning* (ML) [Moon et al. 2022].

3.3. Reinforcement learning-based DDA

3.4. Belgian artificial intelligence

4. Conclusão

Bibliografia

- [Ang and Mitchell 2017] Ang, D. and Mitchell, A. (2017). Comparing effects of dynamic difficulty adjustment systems on video game experience. In *Proceedings of the annual symposium on computer-human interaction in play*, pages 317–327.
- [Bontchev 2016] Bontchev, B. (2016). Adaptation in affective video games: A literature review. *Cybernetics and Information Technologies*, 16(3):3–34.
- [Constant and Levieux 2019] Constant, T. and Levieux, G. (2019). Dynamic difficulty adjustment impact on players’ confidence. In *Proceedings of the 2019 CHI conference on human factors in computing systems*, pages 1–12.
- [Demediuk et al. 2017] Demediuk, S., Tamassia, M., Raffaele, W. L., Zambetta, F., Li, X., and Mueller, F. (2017). Monte carlo tree search based algorithms for dynamic difficulty adjustment. In *2017 IEEE conference on computational intelligence and games (CIG)*, pages 53–59. IEEE.
- [Denisova and Cairns 2015] Denisova, A. and Cairns, P. (2015). Adaptation in digital games: the effect of challenge adjustment on player performance and experience. In *Proceedings of the 2015 annual symposium on computer-human interaction in play*, pages 97–101.
- [Duque et al. 2020] Duque, M. G., Palm, R. B., Ha, D., and Risi, S. (2020). Finding game levels with the right difficulty in a few trials through intelligent trial-and-error. corr abs/2005.07677 (2020). *arXiv preprint arXiv:2005.07677*.
- [Fuchs et al. 2024] Fuchs, R., Gieseke, R., and Dockhorn, A. (2024). Personalized dynamic difficulty adjustment imitation learning meets reinforcement learning. In *2024 IEEE Conference on Games (CoG)*, pages 1–2. IEEE.
- [Ishihara et al. 2018] Ishihara, M., Ito, S., Ishii, R., Harada, T., and Thawonmas, R. (2018). Monte-carlo tree search for implementation of dynamic difficulty adjustment fighting game ais having believable behaviors. In *2018 IEEE Conference on Computational Intelligence and Games (CIG)*, pages 1–8. IEEE.
- [Kim et al. 2020] Kim, D.-W., Park, S., and Yang, S.-i. (2020). Mastering fighting game using deep reinforcement learning with self-play. In *2020 IEEE Conference on Games (CoG)*, pages 576–583. IEEE.
- [Kivikangas et al. 2011] Kivikangas, J. M., Chanel, G., Cowley, B., Ekman, I., Salminen, M., Järvelä, S., and Ravaja, N. (2011). A review of the use of psychophysiological methods in game research. *journal of gaming & virtual worlds*, 3(3):181–199.
- [Lara-Alvarez et al. 2018] Lara-Alvarez, C., Mitre-Hernandez, H., Flores, J. J., and Pérez-Espinosa, H. (2018). Induction of emotional states in educational video games through a fuzzy control system. *IEEE Transactions on Affective Computing*, 12(1):66–77.
- [Lavoué et al. 2018] Lavoué, E., Monterrat, B., Desmarais, M., and George, S. (2018). Adaptive gamification for learning environments. *IEEE Transactions on Learning Technologies*, 12(1):16–28.

- [Lopes and Bidarra 2011] Lopes, R. and Bidarra, R. (2011). Adaptivity challenges in games and simulations: a survey. *IEEE Transactions on Computational Intelligence and AI in Games*, 3(2):85–99.
- [Lora et al. 2016] Lora, D., Sánchez-Ruiz, A. A., González-Calero, P. A., and Gómez-Martín, M. A. (2016). Dynamic difficulty adjustment in tetris. In *FLAIRS*, pages 335–339.
- [Mi and Gao 2022] Mi, Q. and Gao, T. (2022). Improved belgian ai algorithm for dynamic management in action role-playing games. *Applied Sciences*, 12(22):11860.
- [Moon et al. 2022] Moon, J., Choi, Y., Park, T., Choi, J., Hong, J.-H., and Kim, K.-J. (2022). Diversifying dynamic difficulty adjustment agent by integrating player state models into monte-carlo tree search. *Expert Systems with Applications*, 205:117677.
- [Mortazavi et al. 2024] Mortazavi, F., Moradi, H., and Vahabie, A.-H. (2024). Dynamic difficulty adjustment approaches in video games: a systematic literature review. *Multimedia Tools and Applications*, 83(35):83227–83274.
- [Pagalyte et al. 2020] Pagalyte, E., Mancini, M., and Climent, L. (2020). Go with the flow: Reinforcement learning in turn-based battle video games. In *Proceedings of the 20th ACM international conference on intelligent virtual agents*, pages 1–8.
- [Przybylski et al. 2010] Przybylski, A. K., Rigby, C. S., and Ryan, R. M. (2010). A motivational model of video game engagement. *Review of general psychology*, 14(2):154–166.
- [Zeng and Sweetser 2022] Zeng, Z. and Sweetser, P. (2022). Dynamic difficulty adjustment in a multiplayer minecraft server. In *Proceedings of the 34th Australian Conference on Human-Computer Interaction*, pages 319–324.
- [Zohaib 2018] Zohaib, M. (2018). Dynamic difficulty adjustment (dda) in computer games: A review. *Advances in Human-Computer Interaction*, 2018(1):5681652.