

Personagens de jogos mais dinâmicos, uma mini *survey* da literatura

Douglas C. Carvalho¹, Gabriel C. Carvalho¹

¹ Faculdade de Engenharia – Departamento de Engenharia de Sistemas e Computação
Universidade do Estado do Rio de Janeiro (UERJ) – Rio de Janeiro – RJ – Brasil

carvalho.douglas@graduacao.uerj.br, gabrielc@eng.uerj.br

Abstract.

Resumo.

1. Introdução

Durante o processo de desenvolvimento de jogos, os desenvolvedores geralmente se esforçam para manter o engajamento dos jogadores por um longo período [Przybylski et al. 2010]. Isso é particularmente relevante em jogos que possuem algum tipo de combate com *Non-Playable Characters* (NPC), nos quais os desenvolvedores buscam criar videogames com recursos personalizados que aumentem a imersão, o engajamento, a empolgação e o desafio dos jogadores [Bontchev 2016], sem tornar os combates repetitivos e criando uma experiência agradável para o jogador. Dessa forma, a experiência do jogador refere-se ao efeito global de sentimentos, pensamentos, emoções e comportamentos vivenciados pelo jogador durante a partida, incluindo a experiência de imersão, a experiência de participação no jogo e a experiência de satisfação das necessidades [Wiemeyer et al. 2016, Denisova et al. 2016].

Nesse contexto, as medidas heurísticas tradicionais utilizadas em mecânicas de combate são, muitas vezes, limitadas demais para atender à ampla gama de expectativas dos jogadores [Moon et al. 2022]. Como alternativa promissora, tem-se a utilização de *machine learning* (ML) para *Dynamic Difficulty Adjustment* (DDA) em jogos. O DDA é uma tecnologia amplamente utilizada para manter o interesse do jogador e assegurar uma boa experiência de jogo, modificando automaticamente parâmetros, comportamentos e cenas em tempo real, de acordo com o nível de habilidade do jogador [Mi and Gao 2022].

Por isso, foram analisados diversos artigos que abordam diferentes formas de implementação de ML em mecânicas de combate, abrangendo diversos gêneros de jogos, tendo como referência o *survey* [Mortazavi et al. 2024].

2. Método

O método utilizado para analisar os artigos consiste na análise do *abstract* e da conclusão de cada artigo de interesse, com o objetivo de identificar pontos relevantes como a tecnologia proposta, o tipo de jogo testado, o aspecto que se buscou aprimorar no jogo e o objetivo proposto no artigo.

2.1. Base de dados usada na busca

Considerando que os jogos constituem uma área multidisciplinar [Mortazavi et al. 2024], foi utilizado o mecanismo de busca Google Scholar, um mecanismo de busca on-line gratuito que permite pesquisar literatura acadêmica e científica, incluindo artigos revisados por pares, teses, livros e decisões judiciais.

2.2. Termos de busca

Os termos de busca utilizados foram definidos com base na proposta inicial de explorar DDA em jogos, sendo eles:

1. *Intelligent Adaptive Games*
2. *Fighting Games DDA*

A busca na literatura incluiu artigos completos de periódicos e conferências publicados em inglês no período entre 2020 e 2026.

2.3. Critérios de inclusão e exclusão

Os artigos selecionados tiveram que satisfazer os seguintes critérios para serem incluídos na análise:

- Data de publicação entre 2020 e 2026
- 5 ou mais citações

Com base nesses critérios, foram incluídas publicações em periódicos e conferências que desenvolveram e avaliaram empiricamente técnicas para o ajuste dinâmico de dificuldade ou o ajuste adaptativo de níveis de jogo em entretenimento digital.

2.4. Processo de triagem

Com a aplicação dos termos de busca estabelecidos, a seleção foi feita por meio da análise do *abstract* e da conclusão de cada artigo, a fim de determinar sua relevância para a proposta.

Após essa avaliação inicial, restaram seis publicações que satisfizeram as condições de inclusão para uma análise mais detalhada e coleta de dados.

3. Resultados

Nesta seção, os métodos utilizados nos artigos selecionados são analisados com base nos dados apresentados na Tabela 1. Esses dados oferecem uma visão geral dos tipos de artigos publicados na área e dos avanços no ajuste de dificuldade em jogos.

Segundo a literatura, os métodos utilizados podem ser abordados de duas maneiras [Lopes and Bidarra 2011]. A primeira abordagem envolve a manipulação de parâmetros do jogo, como o número de inimigos ou o poder dos oponentes, durante a partida. Os desenvolvedores projetam um sistema de ajuste de nível ou de dificuldade que modifica a dificuldade do jogo com base no desempenho, na personalidade ou nas características dos jogadores [Lara-Alvarez et al. 2018]. A segunda abordagem personaliza o ambiente ou os elementos do jogo com base nas expectativas e características dos jogadores, sendo que os elementos selecionados não determinam necessariamente a dificuldade do jogo [Lavoué et al. 2018].

Nesta *survey*, focamos na análise de artigos que utilizaram a primeira abordagem para a adaptação, em tempo real, dos desafios dos jogos usando *Artificial Intelligence* (AI) para garantir uma experiência satisfatória e envolvente para os jogadores.

Tabela 1. Lista de artigos incluídos

Referência	Método usado	Gênero do jogo	Modificação feita	Objetivo
[Fuchs et al. 2024]	DDA <i>framework</i> personalizado que combina <i>imitation learning</i> e <i>Reinforcement Learning</i>	<i>Fighting</i>	Criação de oponentes que usam AI para se adaptar ao comportamento individual do jogador em tempo real	Explorar o balanceamento da dificuldade do jogo utilizando agentes baseados em ML para desafiar os jogadores de acordo com seu comportamento atual
[Zeng and Sweetser 2022]	DDA ✓	<i>Sandbox</i> e <i>Survival</i>	Sistema de DDA focado no ajuste dos <i>mobs</i> ao redor dos jogadores	Buscar melhorar a experiência de todos os jogadores, adequando melhor os níveis dos <i>mobs</i> aos níveis de habilidade coletivos dos jogadores em uma área local
[Moon et al. 2022]	DDA com <i>Monte Carlo Tree Search</i> e estado do jogador ✓	<i>Fighting</i>	O estado dos jogadores como uma função de pontuação para determinar a ação dos agentes do jogo e ajustar automaticamente a dificuldade do jogo	Melhorar a experiência dos jogadores ajustando a habilidade dos agentes do jogo
[Mi and Gao 2022]	<i>Belgian Artificial Intelligence</i>	<i>Action role-playing</i>	Sistema de gerenciamento de combate	Propor um algoritmo de <i>Belgian Artificial Intelligence</i> melhorado com DDA
[Kim et al. 2020]	Agente de AI usando <i>Deep Reinforcement Learning</i> com <i>self-play</i> e <i>Monte Carlo Tree Search</i>	<i>Fighting</i>	Sistema de gerenciamento de combate	Gerar uma AI para jogos de luta capaz de competir contra outras AIs que participaram de competições anteriores no ambiente de jogos FightingICE
[Pagalyte et al. 2020]	DDA baseado em <i>Reinforcement Learning</i>	<i>Turn-based battle</i>	Modificar as escolhas de ação do agente, em vez do ambiente ou das estatísticas do agente	Alcançar um <i>game flow</i> envolvente por meio da introdução de DDA e <i>Reinforcement Learning</i> em jogos de batalha baseados em turnos

3.1. *Dynamic Difficulty Adjustment*

O *Dynamic Difficulty Adjustment* (DDA) consiste em duas etapas [Zohaib 2018]. Primeiramente, mede-se o nível de habilidade dos jogadores por meio de uma função de pontuação. Em seguida, ajusta-se a dificuldade do jogo de acordo com os níveis de habilidade estimados, de diversas formas, como o ajuste de parâmetros no jogo [Denisova and Cairns 2015], a manipulação do ambiente de jogo [Duque et al. 2020, Lora et al. 2016] e a utilização de agentes de jogo [Demediuk et al. 2017, Ishihara et al. 2018].

3.2. DDA com *Monte Carlo Tree Search* e o estado do jogador

O método que utiliza um agente de DDA baseado em *Monte Carlo tree search* (MCTS) em um jogo de luta é apresentado em [Demediuk et al. 2017, Ishihara et al. 2018]. Nesse método, a dificuldade do jogo é manipulada por meio da implementação de um agente de DDA que utiliza a diferença de *health points* (HP) entre o jogador e o agente como função de pontuação, de maneira semelhante à abordagem apresentada em [Moon et al. 2022].

Contudo, essas técnicas de medição das habilidades dos jogadores, que utilizam funções de pontuação heurísticas especificadas pelos desenvolvedores, pressupõem que o ajuste da dificuldade do jogo por meio dessas métricas (com base em HP, pontuação no jogo, dano, etc.) pode aumentar o *player experience* (PX). No entanto, a PX e a dificuldade do jogo ajustada por essas medidas frequentemente apresentam inconsistências [Ang and Mitchell 2017, Constant and Levieux 2019].

Por isso, em [Moon et al. 2022], os estados do jogador são utilizados no treinamento da IA do jogo juntamente com o MCTS, permitindo que o DDA se ajuste automaticamente e progressivamente às ações dos oponentes. Essa abordagem considera que a dificuldade do jogo pode evocar diversos estados cognitivos e emocionais que podem impactar a PX [Kivikangas et al. 2011]. Nesse contexto, o MCTS busca a próxima ação, considerada quase ótima para a IA do jogo, por meio da simulação de um grande número de situações possíveis a partir do estado atual do jogo.

Para tanto, as simulações do MCTS consistem em quatro etapas: *selection*, *expansion*, *simulation* e *backpropagation*. Em cada iteração, o estado atual é definido como o nó raiz. Em seguida, as quatro etapas da busca em árvore são executadas dentro de um limite de tempo predeterminado. Após a conclusão da busca, o agente escolhe o nó filho mais visitado ou aquele que apresenta o maior valor para realizar a próxima ação [Moon et al. 2022].

Sendo assim, a principal diferença entre o modelo proposto em [Moon et al. 2022] e o método de DDA heurístico é a utilização direta do estado do jogador como função de pontuação para o MCTS, em vez de funções heurísticas, como pontuação do jogo, taxa de vitória e diferença de HP. O modelo do estado do jogador combina registros de partidas reais e de partidas simuladas pelo MCTS para prever como o estado do jogador se modificará no futuro por meio de técnicas de *machine learning* (ML) [Moon et al. 2022].

3.3. DDA baseado em *Reinforcement Learning*

4. Conclusão

Bibliografia

- [Ang and Mitchell 2017] Ang, D. and Mitchell, A. (2017). Comparing effects of dynamic difficulty adjustment systems on video game experience. In *Proceedings of the annual*

symposium on computer-human interaction in play, pages 317–327.

- [Bontchev 2016] Bontchev, B. (2016). Adaptation in affective video games: A literature review. *Cybernetics and Information Technologies*, 16(3):3–34.
- [Constant and Levieux 2019] Constant, T. and Levieux, G. (2019). Dynamic difficulty adjustment impact on players’ confidence. In *Proceedings of the 2019 CHI conference on human factors in computing systems*, pages 1–12.
- [Demediuk et al. 2017] Demediuk, S., Tamassia, M., Raffe, W. L., Zambetta, F., Li, X., and Mueller, F. (2017). Monte carlo tree search based algorithms for dynamic difficulty adjustment. In *2017 IEEE conference on computational intelligence and games (CIG)*, pages 53–59. IEEE.
- [Denisova and Cairns 2015] Denisova, A. and Cairns, P. (2015). Adaptation in digital games: the effect of challenge adjustment on player performance and experience. In *Proceedings of the 2015 annual symposium on computer-human interaction in play*, pages 97–101.
- [Denisova et al. 2016] Denisova, A., Nordin, A. I., and Cairns, P. (2016). The convergence of player experience questionnaires. In *Proceedings of the 2016 annual symposium on computer-human interaction in play*, pages 33–37.
- [Duque et al. 2020] Duque, M. G., Palm, R. B., Ha, D., and Risi, S. (2020). Finding game levels with the right difficulty in a few trials through intelligent trial-and-error. corr abs/2005.07677 (2020). *arXiv preprint arXiv:2005.07677*.
- [Fuchs et al. 2024] Fuchs, R., Gieseke, R., and Dockhorn, A. (2024). Personalized dynamic difficulty adjustment imitation learning meets reinforcement learning. In *2024 IEEE Conference on Games (CoG)*, pages 1–2. IEEE.
- [Ishihara et al. 2018] Ishihara, M., Ito, S., Ishii, R., Harada, T., and Thawonmas, R. (2018). Monte-carlo tree search for implementation of dynamic difficulty adjustment fighting game ais having believable behaviors. In *2018 IEEE Conference on Computational Intelligence and Games (CIG)*, pages 1–8. IEEE.
- [Kim et al. 2020] Kim, D.-W., Park, S., and Yang, S.-i. (2020). Mastering fighting game using deep reinforcement learning with self-play. In *2020 IEEE Conference on Games (CoG)*, pages 576–583. IEEE.
- [Kivikangas et al. 2011] Kivikangas, J. M., Chanel, G., Cowley, B., Ekman, I., Salminen, M., Järvelä, S., and Ravaja, N. (2011). A review of the use of psychophysiological methods in game research. *journal of gaming & virtual worlds*, 3(3):181–199.
- [Lara-Alvarez et al. 2018] Lara-Alvarez, C., Mitre-Hernandez, H., Flores, J. J., and Pérez-Espinosa, H. (2018). Induction of emotional states in educational video games through a fuzzy control system. *IEEE Transactions on Affective Computing*, 12(1):66–77.
- [Lavoué et al. 2018] Lavoué, E., Monterrat, B., Desmarais, M., and George, S. (2018). Adaptive gamification for learning environments. *IEEE Transactions on Learning Technologies*, 12(1):16–28.
- [Lopes and Bidarra 2011] Lopes, R. and Bidarra, R. (2011). Adaptivity challenges in games and simulations: a survey. *IEEE Transactions on Computational Intelligence and AI in Games*, 3(2):85–99.

- [Lora et al. 2016] Lora, D., Sánchez-Ruiz, A. A., González-Calero, P. A., and Gómez-Martín, M. A. (2016). Dynamic difficulty adjustment in tetris. In *FLAIRS*, pages 335–339.
- [Mi and Gao 2022] Mi, Q. and Gao, T. (2022). Improved belgian ai algorithm for dynamic management in action role-playing games. *Applied Sciences*, 12(22):11860.
- [Moon et al. 2022] Moon, J., Choi, Y., Park, T., Choi, J., Hong, J.-H., and Kim, K.-J. (2022). Diversifying dynamic difficulty adjustment agent by integrating player state models into monte-carlo tree search. *Expert Systems with Applications*, 205:117677.
- [Mortazavi et al. 2024] Mortazavi, F., Moradi, H., and Vahabie, A.-H. (2024). Dynamic difficulty adjustment approaches in video games: a systematic literature review. *Multimedia Tools and Applications*, 83(35):83227–83274.
- [Pagalyte et al. 2020] Pagalyte, E., Mancini, M., and Climent, L. (2020). Go with the flow: Reinforcement learning in turn-based battle video games. In *Proceedings of the 20th ACM international conference on intelligent virtual agents*, pages 1–8.
- [Przybylski et al. 2010] Przybylski, A. K., Rigby, C. S., and Ryan, R. M. (2010). A motivational model of video game engagement. *Review of general psychology*, 14(2):154–166.
- [Wiemeyer et al. 2016] Wiemeyer, J., Nacke, L., Moser, C., and ‘Floyd’Mueller, F. (2016). Player experience. In *Serious games: Foundations, concepts and practice*, pages 243–271. Springer.
- [Zeng and Sweetser 2022] Zeng, Z. and Sweetser, P. (2022). Dynamic difficulty adjustment in a multiplayer minecraft server. In *Proceedings of the 34th Australian Conference on Human-Computer Interaction*, pages 319–324.
- [Zohaib 2018] Zohaib, M. (2018). Dynamic difficulty adjustment (dda) in computer games: A review. *Advances in Human-Computer Interaction*, 2018(1):5681652.